### 2. rész

– egy Matlab® alapú megközelítés –

### Baja Zsolt, Vas Orsolya

Matematika és Informatika Intézet, Babeş-Bolyai Tudományegyetem, Kolozsvár, Románia

(bajazsolt98@gmail.com, vas.orsolya@yahoo.com)

10. labor / 2023. december 4-8.



- A 9. labor anyagában bemutatott egy-, illetve kétmintás *U*-próbák alkalmazása során azt feltételeztük, hogy a független mintavételezések olyan normális eloszlásokból származnak, amelyek elméleti várható értékét nem ismerjük, az elméleti szórásukat viszont adottnak tekintettük.
- Ebben a pontban azt feltételezzük, hogy a vizsgált statisztikai sokaság szintén normális eloszlású, de annak sem az elméleti várható értékét, sem a szórását nem ismerjük.
- Ezért célunk egy olyan valószínűségi változó bevezetése, amely segítségével ilyen esetekben is el tudjuk dönteni az elméleti várható értékre vonatkozó nullhipotézis helyességét megbízhatósági intervallumok szerkesztésével, vagy szignifikanciapróba használatával.



Egymintás *T*-próba az ismeretlen elméleti várható értékre

## 1. Tétel (Az egymintás T-próba valószínűségi változója)

Tekintsük az  $X\sim\mathcal{N}\left(\mu,\sigma\right)$  valószínűségi változónak az n-elemű független  $\{X_j\}_{j=1}^n$  mintavételét  $(n\geq 2)$ , ahol  $\mu\in\mathbb{R}$  és  $\sigma>0$ ! Ekkor a

$$T_n = \frac{\overline{X} - \mu}{\frac{\overline{\sigma}}{\sqrt{n}}} = \frac{\overline{X} - \mu}{\sqrt{\frac{\overline{\mu}\xi}{n-1}}} \tag{1}$$

valószínűségi változó Student-eloszlású n-1 szabadságfokkal, ahol

$$\overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_{i}$$

továbbra is az adott mintavétel becsült várható értékét jelöli, továbbá

$$\overline{\mu}_2^c = \frac{1}{n} \sum_{i=1}^n \left( X_j - \overline{X} \right)^2$$

az úgynevezett mintavételi (vagy becsült) másodrendű centrált momentumot,

$$\overline{\sigma} = \sqrt{\frac{n}{n-1} \cdot \overline{\mu}_2^c} = \sqrt{\frac{1}{n-1} \sum_{j=1}^n \left( X_j - \overline{X} \right)^2}$$

pedig a korrigált mintavételi (becsült) szórást jelöli.



Egymintás T-próba az ismeretlen elméleti várható értékre

### Bizonyítás

A bizonyítás megtalálható a nyomtatott jegyzet 182., illetve a digitális változat 189. oldalán!

 Az 1. tétel fényében már tudunk válaszolni az alábbi feladatban megfogalmazott kérdésekre. A megoldás menetéből pedig új statisztikai módszer születik, amelyet egymintás T-próbának nevezünk.

## 1. Feladat (Egymintás *T*-próba)

Tekintsük az  $X \sim \mathcal{N}\left(\mu,\sigma\right)$  valószínűségi változónak az n-elemű független  $\{X_j\}_{j=1}^n$  mintavételét  $(n \geq 2)$ , ahol sem a  $\mu \in \mathbb{R}$  elméleti várható értéket, sem a  $\sigma > 0$  elméleti szórást nem ismerjük! Az  $\alpha \in (0,1)$  szignifikanciaszint mellett döntsük el a  $H_0: \mu = \mu_0$  nullhipotézis helyességét a

```
H_k: \mu \neq \mu_0 (kétoldali próba),

H_j: \mu > \mu_0 (jobb oldali próba),

H_b: \mu < \mu_0 (bal oldali próba)
```

lehetséges alternatív hipotézisekkel szemben, ahol  $\mu_0 \in \mathbb{R}$  egy általunk megfogalmazott tipp az ismeretlen elméleti  $\mu$  várható értékre. Ugyanakkor szerkesszünk mindhárom esetben megbízhatósági intervallumot is az ismeretlen  $\mu$  paraméterre, határozzuk meg az egyes esetekhez tartozó szignifikanciapróbák p-értékét, továbbá implementáljuk is az így adódó statisztikai módszert!



Egymintás T-próba az ismeretlen elméleti várható értékre

### Megoldás

- A feladat megoldását az (1)-es valószínűségi változó használatára vezetjük vissza.
- A 2. labor anyagában már felhívtuk a figyelmet az  $\mathcal{N}$  (0,1)- és az  $\mathcal{S}$  (n)-eloszlások sűrűségfüggvényeinek hasonlóságára, például mindkét sűrűségfüggvény szimmetrikus a függőleges tengelyre nézve, valamint az  $\mathbb{R}$  tartományon el nem tűnő értékeket vesznek fel.
- Emiatt minden olyan képlettel és ábrával párhuzamot vonhatunk, amiket az egymintás U-próba esetén kaptunk.
- Néhány fontos dolgot viszont figyelembe kell vennünk!
  - Mivel az elméleti  $\sigma>0$  szórást nem ismerjük, az  $U_n\sim\mathcal{N}\left(0,1\right)$  valószínűségi változó helyett a  $T_n\sim\mathcal{S}\left(n-1\right)$  változóval kell dolgoznunk, mert az tartalmazza a mintavételt jellemző  $\overline{\sigma}$  becsült korrigált szórást.
  - Ezért az  $F_{\mathcal{N}(0,1)}$  eloszlásfüggvény és annak  $F_{\mathcal{N}(0,1)}^{-1}$  inverze helyett értelemszerűen az  $F_{\mathcal{S}(n-1)}$  eloszlásfüggvényt, illetve ennek  $F_{\mathcal{S}(n-1)}^{-1}$  inverzét kell használnunk.

Egymintás T-próba az ismeretlen elméleti várható értékre

### Megoldás – folytatás

• Ezért a két-, a jobb és a bal oldali próbák esetén az  $1-\frac{\alpha}{2}$ , az  $1-\alpha$ , illetve az  $\alpha$  valószínűségekhez tartozó kvantiliseket rendre a

$$t_{1-\frac{\alpha}{2}} = F_{S(n-1)}^{-1} \left(1 - \frac{\alpha}{2}\right),$$

$$t_{1-\alpha} = F_{S(n-1)}^{-1} (1 - \alpha),$$

$$t_{\alpha} = F_{S(n-1)}^{-1} (\alpha)$$
(2)

alakban határozhatjuk meg.

• Mindhárom alternatív hipotézis esetén, az igaznak feltételezett  $H_0: \mu = \mu_0$  nullhipotézis a

$$T_n^0 = \frac{\overline{X} - \mu_0}{\frac{\overline{\sigma}}{\sqrt{n}}}$$

közös értéket adja, amit a próba t-értékének nevezünk.

Egymintás T-próba az ismeretlen elméleti várható értékre

## Megoldás - folytatás

• A két-, a jobb és a bal oldali próbák esetén rendre az alábbi megbízhatósági intervallumokat kapjuk a  $T_n$  valószínűségi változóra és az ismeretlen  $\mu$  várható értékre:

• 
$$T_n \in (t_{\min}^k, t_{\max}^k) = \left(-t_{1-\frac{\alpha}{2}}, t_{1-\frac{\alpha}{2}}\right),$$

$$\mu \in (\mu_{\min}^k, \mu_{\max}^k) = \left(\overline{X} - \frac{\overline{\sigma}}{\sqrt{n}}t_{1-\frac{\alpha}{2}}, \overline{X} + \frac{\overline{\sigma}}{\sqrt{n}}t_{1-\frac{\alpha}{2}}\right);$$
•  $T_n \in (t_{\min}^j, t_{\max}^j) = (-\infty, t_{1-\alpha}),$ 

$$\mu \in (\mu_{\min}^j, \mu_{\max}^j) = \left(\overline{X} - \frac{\overline{\sigma}}{\sqrt{n}}t_{1-\alpha}, +\infty\right);$$
•  $T_n \in (t_{\min}^b, t_{\max}^b) = (t_{\alpha}, +\infty), \ \mu \in (\mu_{\min}^b, \mu_{\max}^b) = \left(-\infty, \overline{X} - \frac{\overline{\sigma}}{\sqrt{n}}t_{\alpha}\right);$ 

 Ha a H<sub>0</sub>: μ = μ<sub>0</sub> nullhipotézishez rendre a két-, a jobb és a bal oldali alternatív hipotéziseket társítjuk, akkor a megfelelő szignifikanciapróbák p-értékeire rendre az alábbi kifejezéseket kapjuk:

• 
$$p_k = 2P(T_n > |T_n^0| | H_0) = 2F_{S(n-1)}(-|T_n^0|);$$

• 
$$p_i = P(T_n > T_n^0 \mid H_0) = 1 - F_{S(n-1)}(T_n^0);$$

• 
$$p_b = P(T_n < T_n^0 \mid H_0) = F_{S(n-1)}(T_n^0).$$



Egymintás T-próba az ismeretlen elméleti várható értékre

### Megoldás – folytatás

• Jelölje a továbbiakban  $a \in \{k, j, b\}$  az alternatív hipotézis típusát, valamint

$$op_a = \begin{cases} \neq, & a = k, \\ >, & a = j, \\ <, & a = b \end{cases}$$

az egyes alternatív hipotézisekben megjelenő logikai operátorokat!

- Ekkor minden  $a \in \{k, j, b\}$  oldalú próba esetén a szokásos módon dönthetünk: amennyiben  $T_n^0 \in (t_{\max}^a, t_{\max}^a)$ , vagy  $\mu_0 \in (\mu_{\min}^a, \mu_{\max}^a)$ , akkor a  $H_0 : \mu = \mu_0$  nullhipotézist, máskülönben a  $H_a : \mu$  op<sub>a</sub>  $\mu_0$  alternatív hipotézist fogadjuk el.
- Hasonlóképpen, az a ∈ {k, j, b} odalú szignifikanciapróba esetén, ha p<sub>a</sub> > α, akkor a H<sub>0</sub>: μ = μ<sub>0</sub> nullhipotézist, ellenben a H<sub>a</sub>: μ op<sub>a</sub> μ<sub>0</sub> alternatív hipotézist fogadjuk el.
- Az egymintás T-próbát az alábbi MATLAB®-ban írt forráskódban részlegesen implementáltuk az egymintás U-próba kódrészletéhez hasonlóan.
  - Figyeljünk fel arra, hogy az eddig használt normális eloszlás eloszlásfüggvényét és annak inverzét közelítő normcdf, illetve norminv függvények helyett most a Student-féle eloszlásfüggvényt és az ennek inverzét approximáló tcdf, illetve tinv függvényeket hívtuk meg a (2)-es kvantilisek kiértékelése végett!
  - Vegyük észre azt is, hogy a TTest függvény paraméterlistája már nem feltételezi az elméleti σ szórást ismertnek!



## 1. Kódrészlet. Az egymintás T-próba MATLAB $^{\circledR}$ -beli implementálása

```
2 % Description
4 % The function performs a one-sample T-test of the null hypothesis H_0: \mu = \mu_0 that the
5 % data in the vector \mathbf{X}=\{X_j\}_{i=1}^n comes from an \mathcal{N}\left(\mu,\sigma
ight) distribution , where the
6 % theoretical mean value \mu \in \mathbb{R} and the theoretical standard deviation \sigma > 0
7 % are unknown parameters.
8 %
9 % The test is performed against the alternative hypothesis specified by the input
10 % parameter tail.
11 %
12 % —
13 % Input
14 % -----
15 % \mathbf{X} = \{X_j\}_{i=1}^n — an independent and identically distributed sample of the normal distribu —
16 %
                    tion \mathcal{N}(\mu,\sigma), where the theoretical mean value \mu\in\mathbb{R} and the theoretical
17 %
                    standard deviation \sigma > 0 are unknown parameters
18 % mu_0
                 - denotes the guess \mu_0 of the user for the unknown theoretical mean
19 %
                    value \mu
20 % alpha
                 - represents the significance level lpha \in (0,1)
21 % tail
                 — a parameter that can be set either by one of the strings 'both', CLAV
22 %
                    'right'. 'left'. or by using one of the numbers 0.1.-1 (it determines
23 %
                    the type of the alternative hypothesis)
25 % Output
26 % -----
```

### Implementálás – II

```
— confidence interval for the random variable T_n = \frac{\overline{X} - \mu}{\frac{\overline{\sigma}}{\sigma_c}} \sim \mathcal{S}\left(n-1\right)
27 % ci_t
28 % ci_mu
                   - confidence interval for theoretical mean value \mu
29 % t_value
                  - value of the test, assuming that the null hypothesis H_0: \mu = \mu_0 is true
                  - probability of observing the given result, or one more extreme, by
30 % p_value
                      chance if the null hypothesis H_0: \mu = \mu_0 is true (small p-values
31 %
32 %
                      cast doubt on the validity of the null hypothesis)
33 % H
                   — the code of the accepted hypothesis (0 = \text{null hypothesis},
34 %
                      1 = alternative hypothesis defined by the input parameter tail)
35 %
36 function [ci_t, ci_mu, t_value, p_value, H] = TTest(X, mu_0, alpha, tail)
37
38 % check the validity of input parameters!
39 . . .
40
41 % get the size of the sample \{X_j\}_{j=1}^n
42 n = length(X);
43
44 % calculate the sample mean \overline{X} = \frac{1}{n} \sum_{i=1}^{n} X_{j}
45 X_{-} = sum(X) / n; % or, equivalently, X_{-} = mean(X);
47 % calculate the sample standard deviation \overline{\sigma} = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2}
48 sigma_ = sqrt(sum((X - X_{-}).^2) / (n-1)); % or, equivalently, sigma_ = sqrt(var(X));
49
```

### Implementálás – III

```
50 % observe that \frac{\sigma}{\sqrt{s}} is a constant
51 s = sigma_{-} / sqrt(n);
52
53 % calculate the t-value T_n^0 = \frac{\overline{X} - \mu_0}{\overline{\sigma}_{\overline{n}}}
54 t_value = (X_- mu_0) / s;
    % calculate the confidence intervals
    switch (tail)
           case {'both', 0}
58
                 % calculate the inverse function value t_{1-\frac{\alpha}{2}} = F_{S(n-1)}^{-1} \left(1-\frac{\alpha}{2}\right)
59
                 t = tinv(1 - alpha/2, n-1);
60
61
                 % store the end points of the confidence interval \left(-t_{1-\frac{\alpha}{2}},+t_{1-\frac{\alpha}{2}}\right)
62
63
                 ci_t(1) = -t:
                 ci_t(2) = t:
64
65
                 % store the end points of the confidence interval \left(\overline{X} - \frac{\overline{\sigma}}{\sqrt{n}}t_{1-\frac{\alpha}{2}}, \overline{X} + \frac{\overline{\sigma}}{\sqrt{n}}t_{1-\frac{\alpha}{2}}\right)
66
                 ci_mu(1) = X_- - s * t;
67
                 ci_mu(2) = X_+ + s * t;
68
                 % calculate the p-value p = 2F_{S(n-1)} \left( - \left| T_n^0 \right| \right)
70
                 p_value = 2.0 * tcdf(-abs(t_value), n-1);
71
```

### Implementálás – IV

```
case {'right', 1}
73
74
75
      case {'left', -1}
76
77
78 end
79
80 % make your decision based on confidence intervals, and note that, the
81 % condition (mu_0 > ci_mu(1) \&\& mu_0 < ci_mu(2)) would also be correct!
82 H = (t_value > ci_t(1) \& t_value < ci_t(2));
83
84 % do you have any doubt? — if yes, then apply the corresponding significance test!
85 if (p_value < alpha)
       disp('Warning:_small_p-value_cast_doubt_on_the_validity_of_the_null-hypothesis!');
87 end
```



Kétmintás T-próba az ismeretlen elméleti várható értékek összehasonlítására

- A kétmintás *U*-próbához hasonlóan ebben a pontban is két független, nem feltétlenül azonos normális eloszlású valószínűségi változó ismeretlen elméleti várható értékét hasonlítjuk össze azzal a különbséggel, hogy az ismeretlen elméleti várható értékek mellett az adott valószínűségi változók elméleti szórását sem ismerjük, vagyis az összehasonlítás érdekében a változóknak csak egy-egy független mintavételét tekintjük adottnak.
- A hamarosan ismertetendő kétmintás T-próbát különböző módon kell majd végrehajtani aszerint, hogy az elméleti szórások ismeretlenek, de megegyeznek, vagy az elméleti szórások ismeretlenek, viszont értékeik különbözőek. Éppen ezért két új valószínűségi változót is bevezetünk az alábbi tételekben. (Kiegészítésként lásd a nyomtatott jegyzet 186–187., illetve az elektronikus változat 193–194. oldalait!)



Kétmintás T-próba az ismeretlen elméleti várható értékek összehasonlítására

# 2. Tétel (A kétmintás T-próba valószínűségi változója, ha az elméleti szórások megegyeznek)

Tekintsük az  $X \sim \mathcal{N}\left(\mu_1, \sigma\right)$  és  $Y \sim \mathcal{N}\left(\mu_2, \sigma\right)$  független valószínűségi változókat, valamint ezeknek egy-egy független  $\{X_i\}_{i=1}^m$  és  $\left\{Y_j\right\}_{j=1}^n$  mintavételét  $(m \geq 2, n \geq 2)$ , ahol  $\mu_1, \mu_2 \in \mathbb{R}$  és  $\sigma > 0$ ! Ekkor a

$$T_{m,n} = \frac{\left(\overline{X} - \overline{Y}\right) - (\mu_1 - \mu_2)}{\sqrt{(m-1)\overline{\sigma}_1^2 + (n-1)\overline{\sigma}_2^2}} \cdot \sqrt{\frac{m+n-2}{\frac{1}{m} + \frac{1}{n}}}$$
(3)

valószínűségi változó  $\mathcal{S}\left(m+n-2\right)$ -eloszlást követ, ahol

$$\overline{X} = \frac{1}{m} \sum_{i=1}^{m} X_i, \ \overline{Y} = \frac{1}{n} \sum_{j=1}^{n} Y_j$$

a mintavételi becsült várható értékeket,

$$\overline{\sigma}_1^2 = \frac{1}{m-1} \sum_{i=1}^m \left( X_i - \overline{X} \right)^2, \ \overline{\sigma}_2^2 = \frac{1}{n-1} \sum_{j=1}^n \left( Y_j - \overline{Y} \right)^2$$

pedig a becsült korrigált szórásnégyzeteket jelölik.



Kétmintás T-próba az ismeretlen elméleti várható értékek összehasonlítására

# 3. Tétel (A kétmintás T-próba valószínűségi változója, ha az elméleti szórások különbözőek)

Tekintsük az  $X \sim \mathcal{N}\left(\mu_1, \sigma_1\right)$  és  $Y \sim \mathcal{N}\left(\mu_2, \sigma_2\right)$  független valószínűségi változókat, valamint ezeknek egy-egy független  $\{X_i\}_{i=1}^m$  és  $\{Y_j\}_{j=1}^n$  mintavételét  $(m \geq 2, \ n \geq 2)$ , ahol  $\mu_1, \mu_2 \in \mathbb{R}, \ \sigma_1, \sigma_2 > 0$ , továbbá  $\sigma_1 \neq \sigma_2$ ! Ekkor a

$$T_{m,n} = \frac{\left(\overline{X} - \overline{Y}\right) - (\mu_1 - \mu_2)}{\sqrt{\frac{\overline{\sigma}_1^2}{m} + \frac{\overline{\sigma}_2^2}{n}}} \tag{4}$$

valószínűségi változó  $\mathcal{S}(\eta)$ -eloszlást követ, ahol az  $\eta$  szabadsáfokot (alakparamétert) súlyozással állíthatjuk elő az

$$\begin{split} &\frac{1}{\eta} = \frac{w^2}{m-1} + \frac{(1-w)^2}{n-1}, \\ &w = \frac{\frac{\overline{\sigma}_1^2}{m}}{\frac{\overline{\sigma}_1^2}{1} + \frac{\overline{\sigma}_2^2}{2}} \end{split}$$

képletek segítségével.



Kétmintás T-próba az ismeretlen elméleti várható értékek összehasonlítására

### 2. Feladat (Kétmintás *T*-próba)

Tekintsük az  $X \sim \mathcal{N}\left(\mu_1, \sigma_1\right)$  és  $Y \sim \mathcal{N}\left(\mu_2, \sigma_2\right)$  független valószínűségi változókat, valamint ezeknek egy-egy független  $\{X_i\}_{i=1}^m$  és  $\{Y_j\}_{j=1}^n$  mintavételét  $(m \geq 2, n \geq 2)$ , ahol sem az elméleti  $\mu_1, \mu_2 \in \mathbb{R}$  várható értékeket, sem az elméleti  $\sigma_1, \sigma_2 > 0$  szórásokat nem ismerjük! Az  $\alpha \in (0,1)$  szignifikanciaszint mellett döntsük el a

$$H_0: \mu_1 - \mu_2 = 0$$

nullhipotézis helyességét a

$$H_k: \mu_1 - \mu_2 \neq 0$$
 (kétoldali próba),  
 $H_j: \mu_1 - \mu_2 > 0$  (jobb oldali próba),  
 $H_b: \mu_1 - \mu_2 < 0$  (bal oldali próba)

lehetséges alternatív hipotézisekkel szemben! Ugyanakkor szerkesszünk mindhárom esetben megbízhatósági intervallumot az ismeretlen elméleti várható értékek  $\mu_1-\mu_2$  különbségére, határozzuk meg az egyes esetekhez tartozó szignifikanciapróbák p-értékét, továbbá implementáljuk is ezt a statisztikai módszert!

Egymintás T-próba az ismeretlen elméleti várható értékre

### Megoldás – folytatás

- A feladatot csak vázlatosan oldjuk meg, mert a megoldás mikéntje teljesen hasonló az egymintás T-próba módszeréhez, amelyet az 1. feladatban ismertettünk. A részletes számítások elvégzését és a 2. kódrészlet befejezését az olvasóra hízzuk!
- Ha az  $X \sim \mathcal{N}\left(\mu_1, \sigma_1\right)$  és  $Y \sim \mathcal{N}\left(\mu_2, \sigma_2\right)$  teljesen ismeretlen paraméterezésű valószínűségi változók szórásairól a  $\sigma_1 = \sigma_2 = \sigma$  megegyezést feltételezzük, akkor, az egymintás T-próbához képest, a  $T_n$  valószínűségi változó helyett a (3)-as, máskülönben a (4)-es kifejezésben adott  $T_{m,n}$  valószínűségi változó használatára vezethetjük vissza a feladatot.
- A továbbiakban a szórásokkal kapcsolatos esetszétválasztásnak megfelelően felsoroljuk mindhárom alternatív hipotézishez tartozó konfidenciaintervallumokat, valamint a megfelelő szignifikanciapróbák p-értékét is feltüntetjük.
- Vezessük be az

$$s = \left\{egin{array}{ll} \sqrt{\left(\left(m-1
ight)\overline{\sigma}_1^2 + \left(n-1
ight)\overline{\sigma}_2^2
ight) \cdot rac{m+n}{mn\left(m+n-2
ight)}}, & \sigma_1 = \sigma_2 = \sigma, \ & \sqrt{rac{\overline{\sigma}_1^2}{m} + rac{\overline{\sigma}_2^2}{n}}, & \sigma_1 
eq \sigma_2 \end{array}
ight.$$

konstanst.

Egymintás T-próba az ismeretlen elméleti várható értékre

### Megoldás – folytatás

• Ekkor  $H_0: \mu_1 - \mu_2 = 0$  nullhipotézist igaznak tartva, a kétmintás T-próba t-értékére a

$$T_{m,n}^0 = \frac{\left(\overline{X} - \overline{Y}\right) - 0}{s} = \frac{\overline{X} - \overline{Y}}{s}$$

kifejezést kapjuk.

Jelölje

$$\eta = \begin{cases} m+n-2, & \sigma_1 = \sigma_2 = \sigma, \\ \frac{(m-1)(n-1)}{(m-1)(1-w)^2 + (n-1)w^2}, & \sigma_1 \neq \sigma_2 \end{cases}$$

az esetszétválasztásnak megfelelő szabadságfokot (alakparamétert), ahol

$$w = \frac{n\overline{\sigma}_1^2}{n\overline{\sigma}_1^2 + m\overline{\sigma}_2^2}!$$

Egymintás T-próba az ismeretlen elméleti várható értékre

### Megoldás – folytatás

Ekkor a

$$T_{m,n} = rac{\left(\overline{X} - \overline{Y}
ight) - (\mu_1 - \mu_2)}{s}$$

valószínűségi változó  $\mathcal{S}\left(\eta\right)$ -eloszlást követ. Ezért, amikor a  $H_0: \mu_1 = \mu_2$  nullhipotézhez a két-, a jobb, és a bal odali alternatív hipotéziseket társítjuk, akkor az  $1-\frac{\alpha}{2}, \ 1-\alpha$ , illetve  $\alpha$  valószínűségekhez tartozó kvantilisekre rendre a

$$t_{1-\frac{\alpha}{2}} = F_{S(\eta)}^{-1} \left(1 - \frac{\alpha}{2}\right),$$

$$t_{1-\alpha} = F_{S(\eta)}^{-1} \left(1 - \alpha\right),$$

$$t_{\alpha} = F_{S(\eta)}^{-1} \left(\alpha\right)$$
(5)

inverz értékeket kapjuk.

## Megoldás - folytatás

• A két-, a jobb és a bal oldali próbák esetén rendre az alábbi megbízhatósági intervallumokat kapjuk a  $T_{m,n}$  valószínűségi változóra és az ismeretlen várható értékek  $\delta=\mu_1-\mu_2$  különbségére:

• 
$$T_{m,n} \in (t_{\min}^k, t_{\max}^k) = (-t_{1-\frac{\alpha}{2}}, t_{1-\frac{\alpha}{2}}),$$
  
 $\delta \in (\delta_{\min}^k, \delta_{\max}^k) = (\overline{X} - \overline{Y} - s \cdot t_{1-\frac{\alpha}{2}}, \overline{X} - \overline{Y} + s \cdot t_{1-\frac{\alpha}{2}});$ 

• 
$$T_{m,n} \in \left(t_{\min}^{j}, t_{\max}^{j}\right) = (-\infty, t_{1-\alpha}),$$
  
 $\delta \in \left(\delta_{\min}^{j}, \delta_{\max}^{j}\right) = \left(\overline{X} - \overline{Y} - s \cdot t_{1-\alpha}, +\infty\right);$ 

• 
$$T_{m,n} \in (t_{\min}^b, t_{\max}^b) = (t_{\alpha}, +\infty), \ \delta \in (\delta_{\min}^b, \delta_{\max}^b) = (-\infty, \overline{X} - \overline{Y} - s \cdot t_{\alpha}).$$

• Ha a  $H_0: \mu_1 = \mu_2$  nullhipotézishez rendre a két-, a jobb és a bal oldali alternatív hipotéziseket társítjuk, akkor a megfelelő oldalú szignifikanciapróbák p-értékeire rendre az alábbi valószínűségeket kapjuk:

• 
$$p_k = 2P(T_{m,n} > |T_{m,n}^0| | H_0) = 2F_{S(\eta)}(-|T_{m,n}^0|);$$

• 
$$p_j = P(T_{m,n} > T_{m,n}^0 \mid H_0) = 1 - F_{S(\eta)}(T_{m,n}^0);$$

• 
$$p_b = P(T_{m,n} < T_{m,n}^0 \mid H_0) = F_{S(\eta)}(T_{m,n}^0).$$

Egymintás T-próba az ismeretlen elméleti várható értékre

## Megoldás – folytatás

- Minden  $a \in \{k,j,b\}$  oldalú kétmintás T-próba esetén a szokásos módon dönthetünk: amennyiben  $T^0_{m,n} \in (t^a_{\min}, t^a_{\max})$ , vagy  $0 \in (\delta^a_{\min}, \delta^a_{\max})$ , akkor a  $H_0: \mu_1 = \mu_2$  nullhipotézist, máskülönben a  $H_a: \mu_1$  op $_a \mu_2$  alternatív hipotézist fogadjuk el.
- Hasonlóképpen, az  $a \in \{k,j,b\}$  odalú szignifikanciapróba esetén, ha  $p_a > \alpha$ , akkor a  $H_0: \mu_1 = \mu_2$  nullhipotézist, ellenben a  $H_a: \mu_1$  op $_a$   $\mu_2$  alternatív hipotézist fogadjuk el.



## 2. Kódrészlet. A kétmintás ${\mathcal T}$ -próba részleges MATLAB $^{f R}$ -beli implementálása

```
2 % Description
4 % The function performs a two-sample T-test of the null hypothesis H_0: \mu_1 = \mu_2 that the
5 % data in the two independent samples \mathbf{X}=\{X_i\}_{i=1}^m and \mathbf{Y}=\{Y_i\}_{i=1}^n , of random variables
6 % X \sim \mathcal{N}(\mu_1, \sigma_1) and Y \sim \mathcal{N}(\mu_2, \sigma_2), come from distributions with equal theoretical means
7 % with unknown (and not necessarily equal) theoretical standard deviations.
8 %
9 % The test is performed against the alternative hypothesis specified by the input
10 % parameter tail.
11 %
12 % —
13 % Input
14 % ---
15 % \mathbf{X} = \{X_i\}_{i=1}^m — an independent and identically distributed sample of the normal
                     distribution \mathcal{N}(\mu_1, \sigma_1), where both parameters \mu_1 \in \mathbb{R} and \sigma_1 > 0
16 %
17 %
                     are unknown
18 % \mathbf{Y} = \{Y_j\}_{i=1}^n — an independent and identically distributed sample of the normal
19 %
                     distribution \mathcal{N}(\mu_2, \sigma_2), where both parameters \mu_2 \in \mathbb{R} and \sigma_2 > 0
20 %
                     are unknown
21 % equal_std — a boolean variable which specifies whether the unknown standard
22 %
                     deviations \sigma_1 and \sigma_2 are equal
23 % alpha
                  - represents the significance level \alpha \in (0,1)
24 % tail
                  - a parameter that can be set either by one of the strings 'both',
25 %
                     'right'. 'left'. or by using one of the numbers 0, 1, -1 (it determines
26 %
                     the type of the alternative hypothesis)
```

```
29 % Output
30 % —
                       - confidence interval for the random variable
31 % ci_t
32 %
                          T_{m,n} = \begin{cases} \frac{\left(\overline{X} - \overline{Y}\right) - \left(\mu_1 - \mu_2\right)}{\sqrt{(m-1)\overline{\sigma}_1^2 + (n-1)\overline{\sigma}_2^2}} \cdot \sqrt{\frac{m+n-2}{\frac{1}{m} + \frac{1}{n}}}, & \sigma_1 = \sigma_2, \\ \\ \frac{\left(\overline{X} - \overline{Y}\right) - \left(\mu_1 - \mu_2\right)}{\sqrt{\frac{-1}{2} + \frac{\overline{\sigma}_2^2}{2}}}, & \sigma_1 \neq \sigma_2 \end{cases}
33 %
34 %
35 % ci_delta — confidence interval for the difference \delta=\mu_1-\mu_2 of the theoretical
                          mean values
37 % t_value — value of the test, assuming that the null hypothesis H_0: \mu_1 = \mu_2 is true
38 % p-value — probability of observing the given result, or one more extreme, by chance
                           if the null hypothesis H_0: \mu_1 = \mu_2 is true (small p-values cast doubt on
                       the validity of the null hypothesis)
40 %
41 % H
                       — the code of the accepted hypothesis (0 = \text{null hypothesis}, 1 = \text{alternative}
42 %
                           hypothesis defined by the input parameter tail)
44 function [ci_t , ci_delta , t_value , p_value , H] = TTest2D(X, Y, equal_std , alpha , tail)
46 % check the validity of input parameters!
48
49 % get the size of the given samples \{X_i\}_{i=1}^m and \{Y_j\}_{i=1}^n
```

## Implementálás – III

```
50 \text{ m} = \text{length}(X):
51 n = length(Y);
 52
 53 \ \% \ \text{calculate the constant} \ s = \left\{ \begin{array}{l} \sqrt{\left(\left(m-1\right)\overline{\sigma}_1^2 + \left(n-1\right)\overline{\sigma}_2^2\right) \cdot \frac{m+n}{mn\left(m+n-2\right)}}, \quad \  \sigma_1 = \sigma_2, \\ \\ \sqrt{\frac{\overline{\sigma}_1^2}{m} + \frac{\overline{\sigma}_2^2}{n}}, \quad \  \sigma_1 \neq \sigma_2 \end{array} \right. 
54 \text{ sigma}_1_2_ = \text{var}(X);
     sigma_2_2 = var(Y):
      if (equal_std)
               s = sqrt(((m-1) * sigma_1_2_ + (n-1) * sigma_2_2_) * (m+n) / m / n / (m+n-2));
               s = sqrt(sigma_1_2_ / m + sigma_2_2_ / n);
      end
 62
```

63 % determine the degree of freedom 
$$\eta=\left\{\begin{array}{c} m+n-2, & \sigma_1=\sigma_2=\sigma,\\ \\ \frac{(m-1)\,(n-1)}{(m-1)\,(1-w)^2+(n-1)\,w^2}, & \sigma_1\neq\sigma_2, \end{array}\right.$$

64 % where 
$$w = \frac{n\overline{\sigma_1^2}}{n\overline{\sigma_1^2} + m\overline{\sigma_2^2}}$$
  
65 if (equal-std)  
66 eta = m + n - 2;  
67 else  
68 w = n \* sigma-1-2- / (n \* sigma-1-2- + m \* sigma-2-2-);  
69 eta = (m - 1) \* (n - 1) / ((m - 1) \* (1 - w)^2 + (n - 1) \* w^2);



```
70 end
71
72 % calculate the difference \overline{X}-\overline{Y}=\frac{1}{m}\sum_{i=1}^{m}X_{i}-\frac{1}{n}\sum_{i=1}^{n}Y_{j} of sample means
73 X_Y_ = mean(X) - mean(Y);
74
75 % calculate the t-value T_{m.n}^0 = \overline{X - \overline{Y}}
76 t_value = X_Y_ / s;
77
    % calculate the confidence intervals
    switch (tail)
          case {'both', 0}
80
                % calculate the inverse function value t_{1-\frac{\alpha}{2}} = F_{S(n)}^{-1} \left(1 - \frac{\alpha}{2}\right)
81
82
                 t = tinv(1 - alpha / 2, eta);
83
                % store the end points of the confidence interval \left(-t_{1-\frac{\alpha}{2}}, +t_{1-\frac{\alpha}{2}}\right)
84
                 ci_t(1) = -t:
85
                 ci_t(2) = t;
86
87
                % store the end points of the confidence interval
88
                \% \left( \overline{X} - \overline{Y} - s \cdot t_{1 - \frac{\alpha}{2}}, \overline{X} - \overline{Y} + s \cdot t_{1 - \frac{\alpha}{2}} \right)
89
90
                 ci_delta(1) = X_Y_ - s * t:
                 ci_delta(2) = X_Y_+ s * t;
91
92
```



```
% calculate the p-value p = 2F_{S(\eta)} \left( - \left| T_{m,n}^0 \right| \right)
93
             p_value = 2.0 * tcdf(-abs(t_value), eta);
94
95
        case {'right', 1}
96
97
        case {'left', -1}
qq
100 end
101
102 % make your decision based on confidence intervals, and note that, the
103 % condition (0 > ci_delta(1) \&\& 0 < ci_delta(2)) would also be correct!
  H = (t_value > ci_t(1) \& t_value < ci_t(2));
105
106 % do you have any doubt? — if yes, then apply the corresponding significance test!
107 if (p_value < alpha)
        disp ('Warning: _small_p-value_cast_doubt_on_the_validity_of_the_null-hypothesis!');
108
109 end
```



### 1. feladat

 Egy kézműves aszalt gyümölcsöket forgalmazó kisvállalatnál ellenőrzést tartanak, amely során lemérik néhány találomra kiválasztott fél kilogrammos tasak aszalt gyümölcs-tartalmát. A mérések grammban kifejezett értékét az

$$X = [501.24, 497.36, 497.54, 498.14, 493.23, 499.76, 498.44, 500.73, 501.32, 498.01, 499.31, 500.75, 498.26, 500.15, 490.18]$$

tömb tartalmazza.

 Tudva, hogy a tasakokban levő aszalt gyümölcsök súlya normális eloszlást követ, döntsétek el 95%-os valószínűség mellett, hogy a tasakokban átlagosan kevesebb aszalt gyümölcs van-e, mint fél kilogramm!

#### 2. feladat

Oldjátok meg a 9. labor feladatait úgy, hogy a szórás(oka)t egyik feladat esetén sem tekintitek ismert paraméter(ek)nek!

### 3. feladat

 Egy acélmegmunkálással foglalkozó üzem vezetője két új automata darabológépet vásárol, amelyeket üzembeállítás előtt egy tesztkör keretén belül próbálnak ki. A próbakör során a gépeknek egy méter hosszúságú acélszalagokat kell vágniuk. A gépek által darabolt acélszalagok centiméterben mért hosszát az

$$X = [104, 100, 102, 98, 103, 99, 100, 97, 107, 102, 103, 100, 98, 102, 100],$$
  
 $Y = [98, 97, 101, 100, 99, 100, 97, 102, 101, 98, 99, 100, 102, 99, 101, 96, 99]$ 

tömbök tartalmazzák.

 Tudva, hogy a gépek által vágott acélszalagok hossza normális eloszlást követ, döntsétek el 92%-os valószínűség mellett, hogy a második automata gép átlagosan rövidebb acélszalagokat vág-e, mint az első gép!